

禅在心中

东风夜放花千树，更吹落、星如雨。宝马雕车香满路。凤箫声动，玉壶光转，一夜鱼龙舞。蛾儿雪柳黄金缕，笑语盈盈暗香去。众里寻他千百度，蓦然回首，那人却在，灯火阑珊处。

< 2021年4月 >						
日	一	二	三	四	五	六
28	29	30	31	1	2	3
4	5	6	7	8	9	10
11	12	13	14	15	16	17
18	19	20	21	22	23	24
25	26	27	28	29	30	1
2	3	4	5	6	7	8

昵称：[禅在心中](#)

园龄：[6年1个月](#)

粉丝：[60](#)

关注：[3](#)

[+加关注](#)

搜索

找找看

常用链接

- [我的随笔](#)
- [我的评论](#)
- [我的参与](#)
- [最新评论](#)
- [我的标签](#)

我的标签

- [机器学习\(23\)](#)
- [深度学习\(10\)](#)
- [python\(10\)](#)
- [VC++学习之路\(8\)](#)
- [Qt\(6\)](#)
- [杂谈\(3\)](#)
- [爬虫\(3\)](#)
- [Thrift\(3\)](#)
- [VS OpenGL\(2\)](#)
- [数据结构和算法\(1\)](#)

随笔档案

- [2020年1月\(3\)](#)
- [2019年12月\(1\)](#)
- [2019年6月\(1\)](#)
- [2018年9月\(1\)](#)
- [2018年8月\(3\)](#)
- [2018年7月\(7\)](#)
- [2018年6月\(5\)](#)
- [2018年5月\(2\)](#)

[博客园](#) [首页](#) [新随笔](#) [新文章](#) [联系](#) [订阅](#) [RSS](#) [管理](#)

posts - 68,comments - 14,views - 52万

隐马尔科夫模型（HMM）与词性标注问题

一、马尔科夫过程：

在已知目前状态（现在）的条件下，它未来的演变（将来）不依赖于它以往的演变（过去）。例如森林中动物头数的变化构成——马尔可夫过程。在现实世界中，有很多过程都是马尔可夫过程，如液体中微粒所作的布朗运动、传染病受感染的人数、车站的候车人数等，都可视为马尔可夫过程。

二、马尔科夫链：

时间和状态都是离散的马尔可夫过程称为马尔可夫链,简记为 $X_n=X(n),n=0,1,2,\dots$

三、马尔可夫模型（Markov Model）：

是一种统计模型，广泛应用在语音识别，词性自动标注，音字转换，概率文法等各个自然语言处理等应用领域。经过长期发展，尤其是在语音识别中的成功应用，使它成为一种通用的统计工具。

一个马尔科夫过程包括一个**初始向量**和一个**状态转移矩阵**。关于这个假设需要注意的一点是状态转移概率不随时间变化。

四、隐马尔科夫模型：

(1) 概述

在某些情况下马尔科夫过程不足以描述我们希望发现的模式。譬如，一个隐居的人可能不能直观的观察到天气的情况，但是有一些海藻。民间的传说告诉我们海藻的状态在某种概率上是和天气的情况相关的。在这种情况下我们有两个状态集合，一个可以观察到的状态集合（海藻的状态）和一个隐藏的状态（天气的状况）。我们希望能找到一个算法可以根据海藻的状况和马尔科夫假设来预测天气的状况。

其中，隐藏状态的数目和可以观察到的状态的数目可能是不一样的。在语音识别中，一个简单的发言也许只需要80个语素来描述，但是一个内部的发音机制可以产生不到80或者超过80种不同的声音。同理，在一个有三种状态的天气系统（sunny、cloudy、rainy）中，也许可以观察到四种潮湿程度的海藻（dry、dryish、damp、soggy）。在此情况下，可以观察到的状态序列和隐藏的状态序列是概率相关的。于是我们可以将这种类型的过程建模为一个**隐藏的马尔科夫过程**和一个**和这个马尔科夫过程概率相关的并且可以观察到的状态集合**。

(2) HMM的模型表示

HMM由**隐含状态S**、**可观测状态O**、**初始状态概率矩阵 $\pi$** 、**隐含状态概率转移矩阵A**、**可观测值转移矩阵B**（混淆矩阵）组成。

$\pi$ 和A决定了状态序列，B决定了观测序列，因此，HMM可以由三元符号表示：

$$\lambda = (A, B, \pi)$$

[2018年4月\(8\)](#)  
[2018年3月\(3\)](#)  
[2018年2月\(2\)](#)  
[2017年12月\(8\)](#)  
[2017年11月\(11\)](#)  
[2017年10月\(2\)](#)  
[2017年6月\(2\)](#)  
[更多](#)

最新评论

1. [Re:RBF \(径向基\) 神经网络](#)

"隐含层的作用是把向量从低维度的p映射到高维度的h" h是做了k-means后的个数, 应该是比p小才对, 至少也不会大于p, 怎么就是映射到高维的h了呢?

--Platelet
2. [Re:Qt中使用匿名函数lambda表达式](#)

学习

--饺子快跑
3. [Re:对于梯度消失和梯度爆炸的理解](#)

你w1的偏导数求的有问题

--wengww
4. [Re:windows下thrift的使用 \(C++\)](#)

哥哥, 就是不会服务端的代码啊, 怎么写, 一般教程里面的Posixxxx都不能用, windows下面

--HengTian
5. [Re:LSTM \(长短期记忆网络\) 及其tensorflow代码应用](#)

请问楼主 pytorch 框架里的LSTM网络 在哪里设置batch size呀 现在在做预测 可是GPU使用率很低

--csuhhhhhh

阅读排行榜

1. [RBF \(径向基\) 神经网络\(121378\)](#)

2. [python中的静态方法和类方法\(47951\)](#)

3. [概率论中常见分布总结以及python的scipy库使用: 两点分布、二项分布、几何分布、泊松分布、均匀分布、指数分布、正态分布\(39819\)](#)

4. [对于梯度消失和梯度爆炸的理解\(34080\)](#)

5. [LSTM \(长短期记忆网络\) 及其tensorflow代码应用\(29816\)](#)

推荐排行榜

1. [RBF \(径向基\) 神经网络\(10\)](#)

2. [C/C++指针参数赋值问题\(2\)](#)

3. [条件随机场 \(crf\) 及tensorflow代码实例\(2\)](#)

4. [python中的静态方法和类方法\(2\)](#)

5. [概率论中常见分布总结以及python的scipy库使用: 两点分布、二项分布、几何分布、泊松分布、均匀分布、指数分布、正态分布\(2\)](#)

HMM的两个性质:

1. 齐次假设:

$$P(i_t|i_{t-1}, o_{t-1}, i_{t-2}, o_{t-2} \cdots i_1, o_1) = P(i_t|i_{t-1})$$

2. 观测独立性假设:

$$P(o_t|i_T, o_T, i_{T-1}, o_{T-1} \cdots i_1, o_1) = P(o_t|i_t)$$

齐次假设: 本质就是时刻t的状态为qi, 原本是要给定t时刻之前的所有状态和观测才可以确定, 但是其实我们给出前一个时刻t-1的状态就可将t时刻与之前隔断, 也就是说我们假设t时刻与t-1之前的所有状态和观测是独立的。

观测独立性假设: 本质就是t时刻的观测为ot, 原本是要给定包括t时刻和t时刻之前所有的观测和状态才能确定, 现在我们给定t时刻状态qi就将ot与前边隔断, 也就是说我们假设t时刻的观测ot与t时刻之前的所有状态和观测是独立的

(3) HMM的三个问题

概率计算问题: 前向-后向算法----动态规划

给定模型  $\lambda = (A, B, \pi)$  和观测序列  $O = \{o_1, o_2, o_3 \dots\}$ , 计算模型  $\lambda$  下观测  $O$  出现的概率  $P(O | \lambda)$

学习问题: Baum-Welch算法----EM算法

已知观测序列  $O = \{o_1, o_2, o_3 \dots\}$ , 估计模型  $\lambda = (A, B, \pi)$  的参数, 使得在该参数下该模型的观测序列  $P(O | \lambda)$  最大

预测问题: Viterbi算法----动态规划

解码问题: 已知模型  $\lambda = (A, B, \pi)$  和观测序列  $O = \{o_1, o_2, o_3 \dots\}$ , 求给定观测序列条件概率  $P(I | O, \lambda)$  最大的状态序列  $I$

a) 概率计算问题

对于概率计算问题, 可以采用暴力计算法、前向算法和后向算法

暴力法:

问题: 已知HMM的参数  $\lambda$ , 和观测序列  $O = \{o_1, o_2, \dots, o_T\}$ , 求  $P(O|\lambda)$

思路: -----

1. 列举所有可能的长度为T的状态序列  $I = \{i_1, i_2, \dots, i_T\}$ ; 每个i都有N个可能的取值。
2. 求各个状态序列I与观测序列 的联合概率  $P(O, I|\lambda)$ ;
3. 所有可能的状态序列求和  $\sum I P(O, I|\lambda)$  得到  $P(O|\lambda)$ 。

步骤:

1, 最终目标是求O和I同时出现的联合概率, 即:

$$P(O, I|\lambda) = P(O|I, \lambda)P(I|\lambda)$$

那就需要求出  $P(O|I, \lambda)$  和  $P(I|\lambda)$ 。

2, 求  $P(I|\lambda)$ , 即状态序列  $I = \{i_1, i_2, \dots, i_T\}$  的概率:

$$2.1, P(I|\lambda) = P(i_1, i_2, \dots, i_T | \lambda)$$

$$= P(i_1 | \lambda)P(i_2, i_3, \dots, i_T | \lambda)$$

$$= P(i_1 | \lambda)P(i_2 | i_1, \lambda)P(i_3, i_4, \dots, i_T | \lambda)$$

$$= \dots$$

$$= P(i_1 | \lambda)P(i_2 | i_1, \lambda)P(i_3 | i_2, \lambda) \dots P(i_T | i_{T-1}, \lambda)$$

而上面的 $P(i_1 | \lambda)$  是初始为状态 $i_1$ 的概率,  $P(i_2 | i_1, \lambda)$  是从状态 $i_1$ 转移到 $i_2$ 的概率, 其他同理, 于是分别使用初始概率分布 $\pi$  和状态转移矩阵 $A$ , 就得到结果:

$$P(I | \lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \cdots a_{i_{T-1} i_T}$$

PS: 上面的 $a_{i_1 i_2}$ 代表 $A$ 的第 $i_1$ 行第 $i_2$ 列。

3,  $P(O | I, \lambda)$ , 即对固定的状态序列 $I$ , 观测序列 $O$ 的概率是:

$$P(O | I, \lambda) = b_{i_1 o_1} b_{i_2 o_2} \cdots b_{i_T o_T}$$

4, 代入第一步求出 $P(O, I | \lambda)$ 。

$$P(O, I | \lambda) = P(O | I, \lambda) P(I | \lambda) = \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \cdots a_{i_{T-1} i_T} b_{i_T o_T}$$

5, 对所有可能的状态序列 $I$ 求和得到观测序列 $O$ 的概率 $P(O | \lambda)$ :

$$\begin{aligned} P(O | \lambda) &= \sum_I P(O, I | \lambda) = \sum_I P(O | I, \lambda) P(I | \lambda) \\ &= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \cdots a_{i_{T-1} i_T} b_{i_T o_T} \end{aligned}$$

时间复杂度:

每个时刻有 $n$ 个状态, 一共有 $t$ 个时刻, 而根据上面的第5步可以知道每个时刻状态 $a_i$ 相乘的复杂度为 $n^T$ , 然后乘以各个对应的 $b$ , 所以时间复杂度大概为:  $O(Tn^T)$ 阶

概率消失:

可以通过取对数, 防止 $P$ 的值过小。

**前向概率:**

前向概率的定义: 当第 $t$ 个时刻的状态为 $i$ 时, 前面的时刻分别观测到 $q_1, q_2, \dots, q_t$ 的概率。

$$\alpha_t(i) = p(q_1, q_2, \dots, q_t, i_t = s_i; \lambda)$$

初值:

$$\alpha_1(i) = p(q_1, i_1 = s_i; \lambda) = \pi_i b_{i q_1}$$

递推:

$$\alpha_{t+1}(i) = \left( \sum_{j=1}^n \alpha_t(j) a_{ji} \right) b_{i q_{t+1}}$$

最终值:

$$P(Q; \lambda) = \sum_{i=1}^n \alpha_T(i)$$

时间复杂度:

由公式可见, 括号里面的时间复杂度为 $N^2$ , 迭代过程中, 又乘上 $T$ 个时刻的 $b$ , 因此, 时间复杂度为 $O(TN^2)$ 阶的。

对于暴力法和前向算法时间复杂度的理解:

对于两种算法，其实本质上都是通过状态  $x$  观测概率获得的概率值，只不过区别在于，前向算法将每一个时刻的状态概率先进行相加然后乘以观测概率，获得最终值。

可以理解为： $a_1*a_2*a_3...$  如果 $a_i$ 有 $n$ 种取值，其复杂度为  $O(n^T)$

对于另一种表达方式： $a*a_1$  同理  $a$ 有 $n$ 种取值， $a_i$ 有 $n$ 种取值，那么复杂度为  $O(n^2)$

时间复杂度计算：

表 1.4.7 对增长数量级的常见假设的总结

描 述	增长的数量级	典型的代码	说 明	举 例
常数级别	1	$a = b + c;$	普通语句	将两个数相加
对数级别	$\log N$	( 请见 1.1.10.2 节, 二分查找 )	二分策略	二分查找
线性级别	$N$	<pre>double max = a[0]; for (int i = 1; i &lt; N; i++)     if (a[i] &gt; max) max = a[i];</pre>	循环	找出最大元素
线性对数级别	$N \log N$	[ 请见算法 2.4 ]	分治	归并排序
平方级别	$N^2$	<pre>for (int i = 0; i &lt; N; i++)     for (int j = i+1; j &lt; N; j++)         if (a[i] + a[j] == 0)             cnt++;</pre>	双层循环	检查所有元素对
立方级别	$N^3$	<pre>for (int i = 0; i &lt; N; i++)     for (int j = i+1; j &lt; N; j++)         for (int k = j+1; k &lt; N; k++)             if (a[i] + a[j] + a[k] == 0)                 cnt++;</pre>	三层循环	检查所有三元组
指数级别	$2^N$	( 请见第 6 章 )	穷举查找	检查所有子集

后向概率和前向概率类似，此处不赘述。

b) 学习问题

学习问题分两种：

- 观测序列和隐状态序列都给出，求HMM。这种学习是监督学习。
- 给出观测序列，但没给出隐状态序列，求HMM。这种学习是非监督学习，利用Baum-Welch(鲍姆-韦尔奇)算法。

对于监督学习，利用大数定律 “频率的极限是概率” 即可求解：

$$\hat{\pi}_i = \frac{|s_i|}{\sum_{i=1}^n |s_i|} \qquad a_{ij} = \frac{|s_{ij}|}{\sum_{j=1}^n |s_{ij}|} \qquad \hat{b}_{ij} = \frac{|q_{ij}|}{\sum_{j=1}^m |q_{ij}|}$$

对于非监督学习，一般采用Baum-Welch算法。

对于观测数据 $Q$ 、隐藏状态 $I$ 、概率 $P(Q, I; \lambda)$ 即为暴力法的表达式，其对数似然函数为： $\ln(P(Q, I; \lambda))$ ，然后用EM算法求解即可。

求  $\pi$ ：利用约束条件：所有 $\pi_i$ 的和为1。

$$\sum_{i=1}^N \ln \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left( \sum_{i=1}^N \pi_i - 1 \right)$$

拉格朗日函数求解：

$$P(O, i_1 = i | \bar{\lambda}) + \gamma \pi_i = 0$$

$$\pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})} = \frac{P(O, i_1 = i | \bar{\lambda})}{\sum_{i=1}^N P(O, i_1 = i | \bar{\lambda})} = \frac{\gamma_1(i)}{\sum_{i=1}^N \gamma_1(i)}$$

同理：

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad b_{ij} = \frac{\sum_{t=1, q_t=o_j}^T \gamma_t(i)}{\sum_{t=1}^T \gamma_t(i)}$$

c) 预测问题：

对于预测问题，本文主要讲Viterbi算法。Viterbi算法实际是用动态规划的思路求解HMM预测问题。求出概率最大的路径，每个路径对应一个状态序列。

盒子球模型 $\lambda = (A, B, \pi)$ ，状态集合 $Q = \{1, 2, 3\}$ ，观测集合 $V = \{\text{白}, \text{黑}\}$ ，已知观测序列“白黑白黑”，求最优的隐藏状态

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix} \quad A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

$$\delta_1(i) = \pi_i b_{iq_1} = \pi_i b_{i\text{白}}$$

$$\delta_1(1) = 0.08$$

$$\delta_1(2) = 0.4$$

$$\delta_1(3) = 0.15$$

$$\delta_2(i) = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{iq_2} = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{i\text{黑}}$$

$$\delta_2(1) = \max\{0.08 * 0.5, 0.4 * 0.2, 0.15 * 0.2\} * 0.6 = 0.048$$

$$\delta_2(2) = \max\{0.08 * 0.4, 0.4 * 0.2, 0.15 * 0.5\} * 0.2 = 0.016$$

$$\delta_2(3) = \max\{0.08 * 0.1, 0.4 * 0.6, 0.15 * 0.3\} * 0.5 = 0.12$$

同理：

$$\delta_3(1) = 0.0096$$

$$\delta_3(2) = 0.048$$

$$\delta_3(3) = 0.018$$

$$\delta_4(1) = 0.00384$$

$$\delta_4(2) = 0.00768$$


$$\delta_4(3) = 0.0144$$

$$\delta_5(1) = 0.001728$$

$$\delta_5(2) = 0.00144$$

$$\delta_5(3) = 0.002304$$

可以看到结果如图：



我们从后往前查询，第5时刻最大概率的状态为3，然后往前推导，究竟第5个状态是从哪一个状态的来的呢？

$\max\{ 0.00384 \times 0.1 \quad 0.00768 \times 0.6 \quad 0.0144 \times 0.3 \}$  可以看到，应该取状态2 -> 3才是最大的，故第4个时刻的状态为2。

最终求得最优状态为：2 3 2 2 3

## 五、viterbi用于词性标注

词性标注问题映射到隐马模型可以表述为：模型中状态(词性)的数目为词性符号的个数N；从每个状态可能输出的不同符号(单词)的数目为词汇的个数M。假设在统计意义上每个词性的概率分布只与上一个词的词性有关(即词性的二元语法)，而每个单词的概率分布只与其词性相关。那么，我们就可以通过对已分词并做了词性标注的训练语料进行统计，统计出HMM的参数  $\lambda$ ，当然这就是上述学习问题。

然后可以根据已知的词语，通过viterbi算法，求出每个词语对应的词性，即完成词性标注。

作者：禅在心中

出处：<http://www.cnblogs.com/pinking/>

本文版权归作者和博客园共有，欢迎批评指正及转载，但未经作者同意必须保留此段声明，且在文章页面明显位置给出原文连接，否则保留追究法律责任的权利。

标签: 机器学习

[好文要顶](#)[关注我](#)[收藏该文](#)



[禅在心中](#)  
[关注 - 3](#)  
[粉丝 - 60](#)

[+加关注](#)

« 上一篇: [机器学习常见问题](#)  
» 下一篇: [深度学习常见的问题](#)

posted on 2018-03-08 22:56 [禅在心中](#) 阅读(5135) 评论(0) [编辑](#) [收藏](#)

[刷新评论](#) [刷新页面](#) [返回顶部](#)

登录后才能查看或发表评论，立即 [登录](#) 或者 [逛逛](#) 博客园首页

- [【推荐】阿里云云小站限量代金券，新老用户同享，上云优惠聚集地](#)
- [【推荐】大型组态、工控、仿真、CAD\GIS 50万行VC++源码免费下载!](#)
- [【推荐】#悄悄变强大# 五一假期提升指南，你若学习，机会自来](#)
- [【推荐】限时秒杀！国云大数据魔镜，企业级云分析平台](#)