doc2vec原理及实践

Johnson0722 包子女孩 2019-09-26

1.“句向量”简介

word2vec提供了高质量的词向量，并在一些任务中表现良好。

关于**word2vec的原理**可以参考这几篇论文：

https://arxiv.org/pdf/1310.4546.pdf

https://arxiv.org/pdf/1301.3781.pdf

关于如何使用第三方库gensim训练word2vec可以参考这篇博客：

http://blog.csdn.net/john_xyz/article/details/54706807

尽管word2vec提供了高质量的词汇向量，仍然没有有效的方法将它们结合成一个高质量的文档向量。对于一个句子、文档或者说一个段落，怎么把这些数据投影到向量空间中，并具有丰富的语义表达呢？过去人们常常使用以下几种方法：

- bag of words
- LDA
- average word vectors
- tfidf-weighting word vectors

就**bag of words**而言，有如下缺点：**1.没有考虑到单词的顺序，2.忽略了单词的语义信息。**因此这种方法对于短文本效果很差，对于长文本效果一般，通常在科研中用来做baseline。

average word vectors就是简单的对句子中的所有词向量取平均。是一种简单有效的方法，但**缺点也是没有考虑到单词的顺序**

tfidf-weighting word vectors是指对句子中的所有词向量根据tfidf权重加权求和，是常用的一种计算sentence embedding的方法，在某些问题上表现很好，相比于简单的对所有词向量求平均，考虑到了tfidf权重，因此句子中更重要的词占得比重就更大。但**缺点也是没有考虑到单词的顺序**

LDA模型当然就是**计算出一片文档或者句子的主题分布。**也常常用于文本分类任务，后面会专门写一篇文章介绍LDA模型和doc2vec的本质不同

2. doc2vec原理

doc2vec是google的两位大牛Quoc Le和Tomas Mikolov在2014年提出的，原始论文地址如下：

https://cs.stanford.edu/~quocle/paragraph_vector.pdf

Doc2Vec 或者叫做 paragraph2vec, sentence embeddings，是一种非监督式算法，可以获得 sentences/paragraphs/documents 的向量表达，是 word2vec 的拓展。学出来的向量可以通过计算距离来找 sentences/paragraphs/documents 之间的相似性，可以用于文本聚类，对于有标签的数据，还可以用监督学习的方法进行文本分类，例如经典的**情感分析**问题。

在介绍doc2vec原理之前，先简单回顾下word2vec的原理

word2vec基本原理

熟悉word2vec的同学都知道，下图是学习词向量表达最经典的一幅图。在下图中，任务就是给定上下文，预测上下文的其他单词。

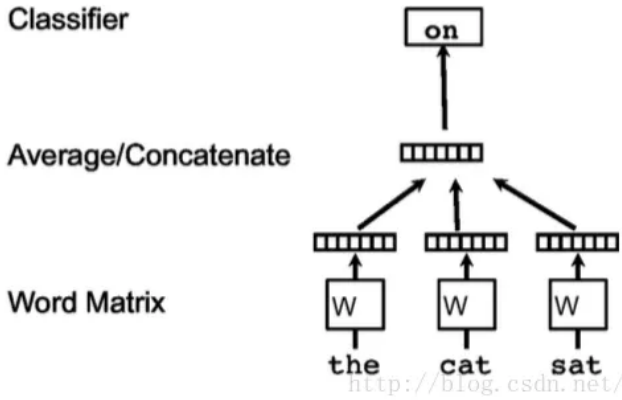

其中，每个单词都被映射到向量空间中，将上下文的词向量级联或者求和作为特征，预测句子中的下一个单词。一般地：给定如下训练单词序列$w_1, w_2, w_3, \ldots, w_T$，目标函数是

$$\frac{1}{T}\sum_{t=k}^{T-k} logp(w_t|w_{t-k}, \ldots, w_{t+k})$$

当然，预测的任务是一个多分类问题，分类器最后一层使用softmax，计算公式如下：

$$p(w_t|w_{t-k}, \ldots, w_{t+k}) = \frac{e^{y_{w_t}}}{\sum_i e^{y_i}}$$

这里的每一个y_i可以理解为预测出每个word的概率。因为在该任务中，每个词就可以看成一个类别。计算y_i的公式如下：

$$y = b + Uh(w_{t-k}, \ldots, w_{t+k}; W)$$

这里U和b都是参数，h是将$w_{t-k}, \ldots, w_{t+k}$级联或者求平均。

因为每个单词都是一类，所以类别众多，在计算softmax归一化的时候，效率很低。因此使用hierarical softmax加快计算速度，其实就是huffman树，这个不再赘述，有兴趣的同学可以看word2vec的paper。

doc2vec基本原理

1. A distributed memory model

训练句向量的方法和词向量的方法非常类似。**训练词向量的核心思想就是说可以根据每个单词w_i的上下文预测w_i**，也就是说上下文的单词对w_i是有影响的。那么同理，可以用同样的方法训练doc2vec。例如对于一个句子s: i want to drink water，如果要去预测句子中的单词want，那么不仅可以根据其他单词生成feature， 也可以根据其他单词和句子ss来生成feature进行预测。因此doc2vec的框架如下所示：

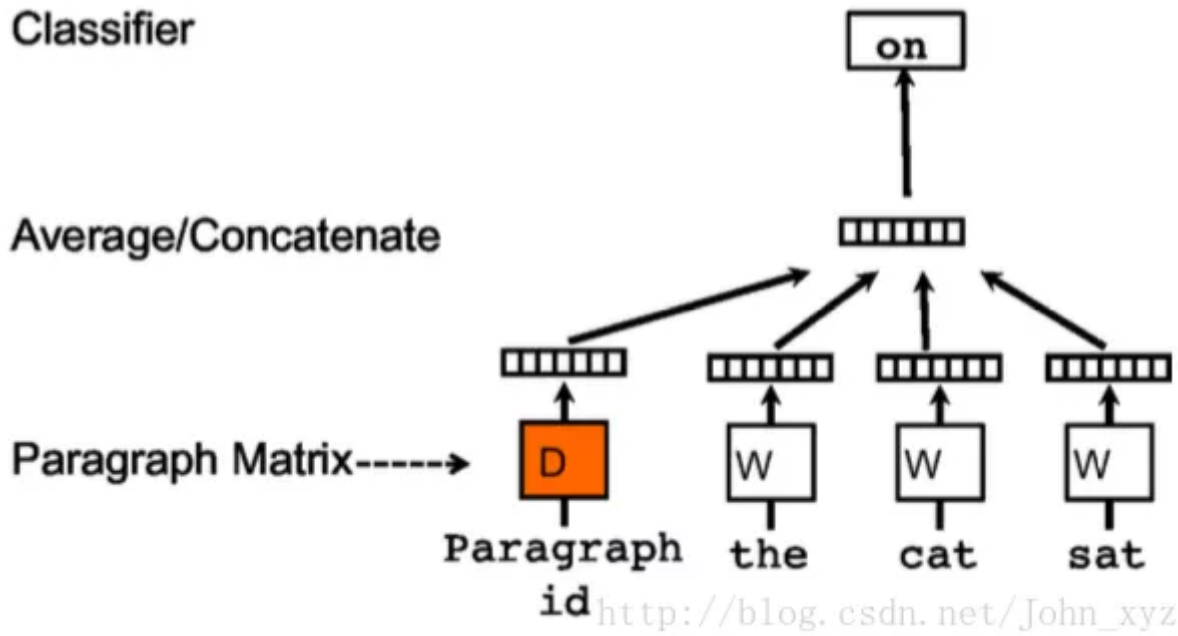

每个段落/句子都被映射到向量空间中，可以用矩阵DD的一列来表示。每个单词同样被映射到向量空间，可以用矩阵WW的一列来表示。然后将段落向量和词向量级联或者求平均得到特征，预测句子中的下一个单词。

这个段落向量/句向量也可以认为是一个单词，**它的作用相当于是上下文的记忆单元或者是这个段落的主题**，所以我们一般叫这种训练方法为Distributed Memory Model of Paragraph Vectors(PV-DM)

在训练的时候我们固定上下文的长度，用滑动窗口的方法产生训练集。段落向量/句向量 在该上下文中共享。

总结doc2vec的过程，主要有两步：

- 训练模型，在已知的训练数据中得到词向量W, softmax的参数U和b,以及段落向量/句向量D
- 推断过程（inference stage），对于新的段落，得到其向量表达。具体地，在矩阵D中添加更多的列，在固定WW,UU,bb的情况下，利用上述方法进行训练，使用梯度下降的方法得到新的D,从而得到新段落的向量表达。

2. Paragraph Vector without word ordering: Distributed bag of words

还有一种训练方法是忽略输入的上下文，让模型去预测段落中的随机一个单词。就是在每次迭代的时候，从文本中采样得到一个窗口，再从这个窗口中随机采样一个单词作为预测任务，让模型去预测，输入就是段落向量。如下所示：

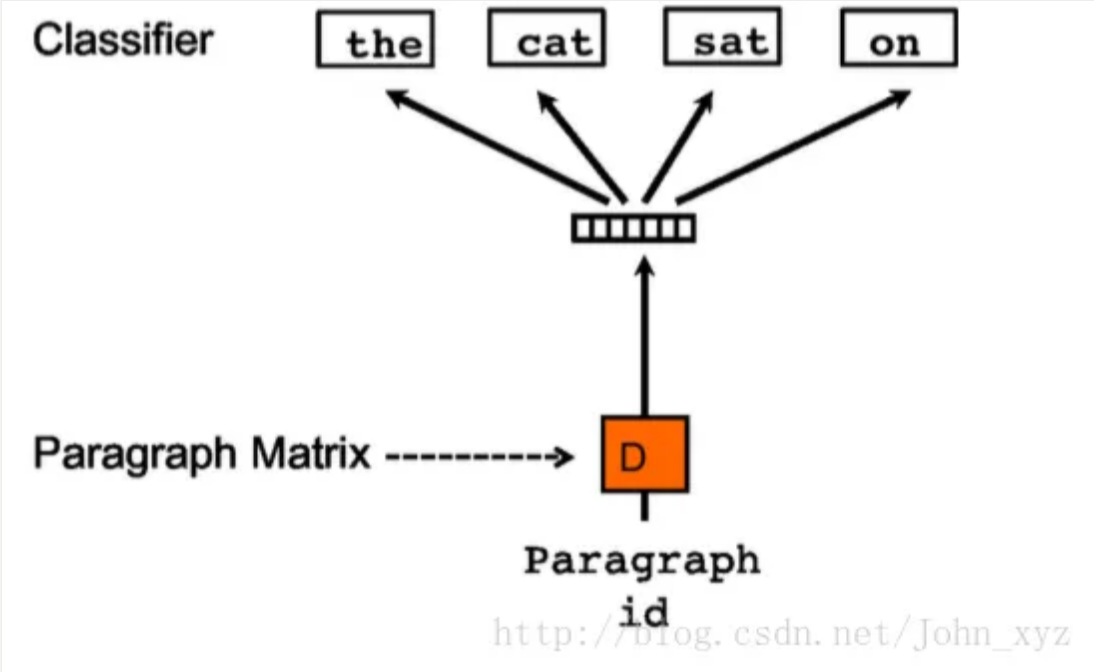

我们称这种模型为 Distributed Bag of Words version of Paragraph Vector(PV-DBOW)

在上述两种方法中，我们可以使用PV-DM或者PV-DBOW得到段落向量/句向量。对于大多数任务，PV-DM的方法表现很好，但我们也强烈推荐两种方法相结合。

3. 基于gensim的doc2vec实践

我们使用第三方库gensim进行doc2vec模型的训练

```
# -*- coding: utf-8 -*-
import sys
import logging
import os
import gensim
# 引入doc2vec
from gensim.models import Doc2Vec
curPath = os.path.abspath(os.path.dirname(__file__))
rootPath = os.path.split(curPath)[0]
sys.path.append(rootPath)
from utilties import ko_title2words

# 引入日志配置
logging.basicConfig(format='%(asctime)s : %(levelname)s : %(message)s',
```

```
15
16  # 加载数据
17  documents = []
18  # 使用count当做每个句子的“标签”，标签和每个句子是一一对应的
19  count = 0
20  with open('../data/titles/ko.video.corpus','r') as f:
21  for line in f:
22          title = unicode(line, 'utf-8')
23  # 切词，返回的结果是列表类型
24          words = ko_title2words(title)
25  # 这里documents里的每个元素是二元组，具体可以查看函数文档
26          documents.append(gensim.models.doc2vec.TaggedDocument(words, [s
27  count += 1
28  if count % 10000 == 0:
29              logging.info('{} has loaded...'.format(count))
30
31  # 模型训练
32  model = Doc2Vec(documents, dm=1, size=100, window=8, min_count=5, worke
33  # 保存模型
34  model.save('models/ko_d2v.model')
```

接下来看看训练好的模型可以做什么

```
1   def test_doc2vec():
2   # 加载模型
3       model = doc2vec.Doc2Vec.load('models/ko_d2v.model')
4   # 与标签‘0’最相似的
5       print(model.docvecs.most_similar('0'))
6   # 进行相关性比较
7       print(model.docvecs.similarity('0','1'))
8   # 输出标签为‘10’句子的向量
9       print(model.docvecs['10'])
10  # 也可以推断一个句向量(未出现在语料中)
11      words = u"여기 나오는 팀 다 가슴"
12      print(model.infer_vector(words.split()))
13  # 也可以输出词向量
14      print(model[u'가슴'])
```